


UNIVERSITATEA POLITEHNICA BUCUREȘTI
FACULTATEA DE ELECTRONICĂ, TELECOMUNICAȚII ȘI TEHNOLOGIA INFORMAȚIEI
DEPARTAMENTUL INGINERIA INFORMAȚIEI



LUCRARE DE DIPLOMA

Aplicație pentru analiza calității aerului

Coordonator

Prof. Radu Hobincu

Student

Aldea Andrei

BUCUREȘTI
2022

Cuprins

Sinopsis.....	3
1. Introducere.....	5
2. Analiza si specificarea cerințelor	7
3. Soluții existente	9
OpenWeather	9
AQICN.....	10
4. Soluția propusa	11
4.1. Tehnologii folosite	11
4.1.1. OpenWeather API.....	11
4.1.2. Java, JavaFX	11
4.1.3. Python	12
4.1.4. Arduino si senzorii utilizați.....	13
4.2. Aplicația	17
Prezentarea generala	17
Colectarea datelor	17
Afișarea datelor.....	18
Procesarea datelor	20
Conectarea la API	28
Detalii relevante	28
4.3. Senzorii	29
Prezentare generala	29
Mărimile măsurate	29
Structura hardware	30
Interfața.....	31
Comunicarea seriala.....	32
5. Evaluarea rezultatelor	33
6. Concluzii.....	37
7. Bibliografie.....	39
8. Lista contribuțiilor personale.....	40
9. Anexe.....	41

Lista Figuri

Figura 1.1.....	6
Figura 3.1.....	9
Figura 3.2.....	10
Figura 3.3.....	10
Figura 4.1.....	13
Figura 4.2.....	14
Figura 4.3.....	15
Figura 4.4.....	19
Figura 4.5.....	24
Figura 4.6.....	25
Figura 4.7.....	26
Figura 4.8.....	27
Figura 4.9.....	28
Figura 4.10.....	30
Figura 4.11.....	31
Figura 4.12.....	32
Figura 5.1.....	36

Lista tabele

Tabel 4.1.....	15
Tabel 4.2.....	22

Sinopsis

Calitatea aerului reprezintă un factor extrem de important în calitatea vieții, putând crea probleme de sănătate atât pe termen scurt cât și pe termen lung. Pentru a putea lua deciziile și măsurile de protecție corecte, este necesară o soluție care să poată raporta starea aerului respirat.


Soluția prezentată oferă utilizatorului posibilitatea de a monitoriza orașul în care se afla, dar și regiunea din jurul acestuia putând astfel urmări schimbarea calității și interacțiunea dintre orașele învecinate. Aerul și mișcările acestuia reprezintă un sistem dinamic și greu de prezis, dar folosind date deja existente putem aproxima modul în care acesta se va comporta. Un element important în calitatea aerului, pe lângă activitățile umane, îl reprezintă vântul, care poate transporta gaze și particule răspândind astfel efectul unei surse de poluare.

1. Introducere

Calitatea aerului reprezintă un factor major în influențarea stării de sănătate a populației, a florei și a faunei, indiferent de regiune sau de mediu, urban sau rural, poluarea poate avea efecte fie pe termen scurt, dar și pe termen lung, problemele cauzate putând rămâne ascunse. Din acest motiv controlul poluării asupra aerului (dar și a celorlalte medii), necesită o atenție deosebit de mare atât din partea instituțiilor de stat cât și din partea cetățenilor.

Poluarea aerului este definită ca fiind contaminarea mediului cu substanțe ce pot afecta starea de sănătate a oamenilor sau a altor organisme vii, sau care pot dauna mediului înconjurător. Chiar dacă există legi în ceea ce privește controlul poluării, această sarcină se dovedește a fi una dificilă, sursele de poluare fiind diverse și uneori imprevizibile, iar prognoza asupra atmosferei nefiind una perfectă. Totuși, monitorizarea aerului și a nivelului de poluare, poate fi o sarcină mai simplă, care poate oferi informații extrem de utile în prevenția apariției problemelor de sănătate. Calitatea aerului în România este reglementată prin Legea nr.104/15.06.2011 privind calitatea aerului înconjurător publicată în Monitorul Oficial al României, Partea I, nr.452 din 28 iunie 2011. [1]

Un studiu al Națiunilor Unite, arată că până în anul 2050, 68% din populația globului va trăi în medii urbane, procentul actual fiind de 55%. Astăzi cele mai urbanizate zone sunt America de nord cu un procent de 82%, America latină cu 81% și Europa cu 74% din populație trăind la oraș. [2] În România gradul de urbanizare a atins în anul 2016 valoare de 57.75%. [3]



Figură 1.1

Aceste creșteri rapide ale concentrației populației în zone restrânse, mediul urban având o densitate a locuitorilor ridicată, duc la creșterea nivelului de poluare a aerului respirat de milioane de oameni care trăiesc în oraș, indiferent de activitățile desfășurate. Simpla deplasare de la domiciliu la locul de muncă, expune populația la riscul dezvoltării bolilor precum alergii, boli de inimă sau cancer. Chiar dacă calitatea scăzută a aerului reprezintă un factor de risc pentru toată populația, unele categorii sunt vulnerabile, precum femeile însărcinate, copiii, persoanele de peste 65 de ani, și cei cu boli cardiovasculare sau cancer. Adicional față de efectul asupra sănătății, poluarea duce și la creșterea costurilor, fiind necesară alocarea unei sume suficient de mari pentru desfășurarea programelor de prevenție și control a acestor fenomene.

2. Analiza si specificarea cerințelor

In lucrarea de fata se dorește realizarea unei aplicații care sa ii permită utilizatorului sa fie informat in legătura cu starea curenta si posibilele schimbări asupra calității aerului si adițional sa ii fie prezentate si informații meteo.

Aplicația va raporta starea curenta a vremii, prezentând astfel informații precum umiditatea si temperatura aerului, viteza vântului si direcția acestuia, date preluate folosind platforma OpenWeather, care pune la dispoziție un API public.

Similar vor fi prezentate date despre starea curenta a calității aerului, calculându-se AQI-ul si prezentând concentrațiile mai multor poluanți precum:

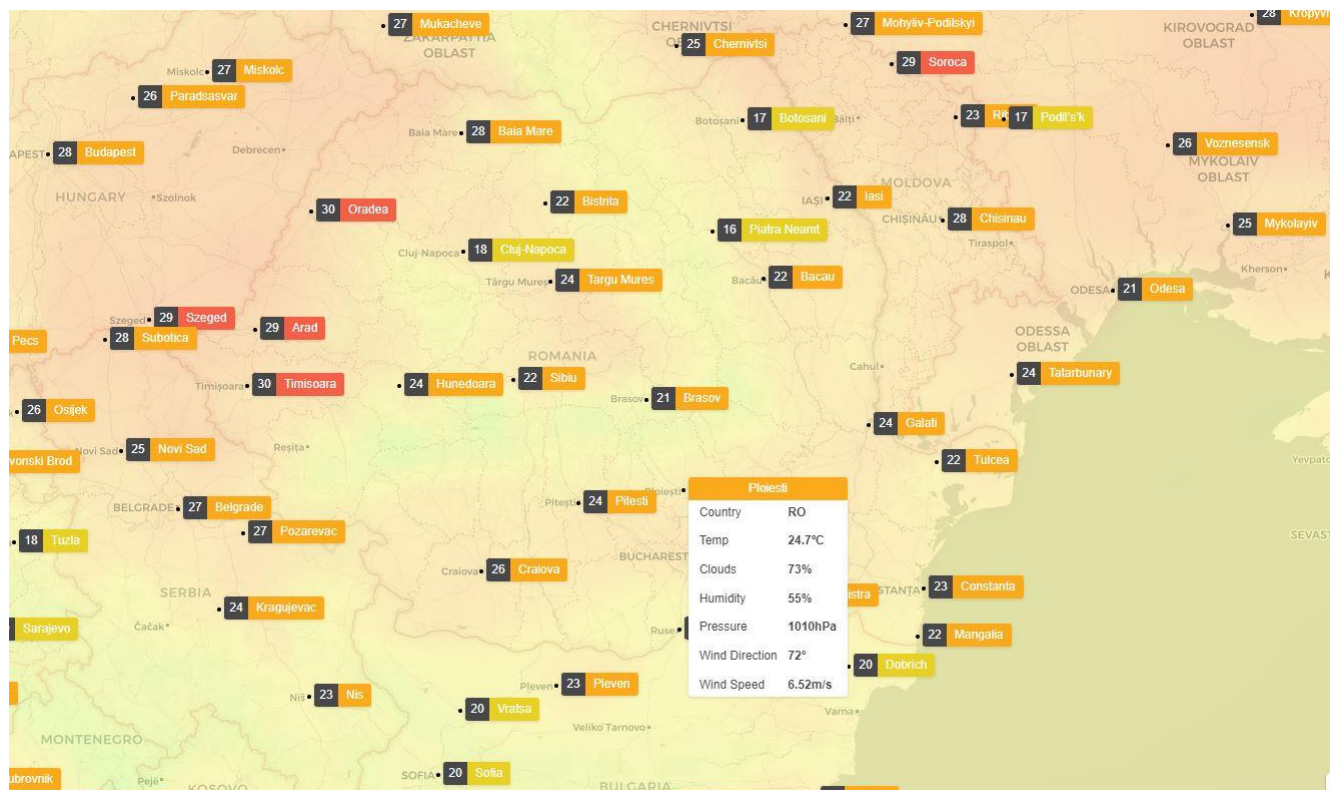
- Monoxidul de carbon (CO), un gaz incolor, inodor si insipid, emanat de arderea combustibililor folosiți in diverse dispozitive care se regăsesc in casele oamenilor;
- Dioxid de sulf (SO₂), emanat la arderea combustibililor, acesta reacționând cu alți compuși din aer produce particule mici care contribuie la concentrația de PM;
- Particulele de mici dimensiuni (PM) reprezintă un mix complex de particule solide si lichide, emanate in principal prin combustia realizata de vehicule, zone industriale sau cea de natura domestica. Clasificarea acestora se face in trei categorii: PM₁₀ – particule (aspre) cu dimensiuni de pana la 10 microni, PM_{2.5} – particule (fine) cu dimensiuni de pana la 2.5 microni si PM_{0.1} – particule (ultra fine) cu dimensiuni de pana la 0.1 microni.
- Dioxid de azot (NO₂) un gaz produs adesea împreuna cu oxidul de azot (NO).
- Amoniac (NH₃), emanat fie din surse naturale sau făcute de om, gazul contribuie la concentrația de PM datorita reacțiilor chimice care duc la producerea de acid sulfuric si acid nitric.
- Ozon (O₃), care spre deosebire de restul gazelor nu este emis in mod direct ci apare prin reacții fotochimice cu gaze precum NO sau NO₂. Efectele produse de acest gaz sunt adesea pe termen scurt, efectele pe termen lung precum bolile cardiovasculare nefiind susținute de foarte multe dovezi.

Având in vedere multitudinea de gaze luate in considerare si diferențele intre acestea, predicția in ceea ce privește modificările concentrațiilor acestora vor fi realizate folosind modele diferite, căutat astfel obținerea unui rezultat cat mai apropiat de realitate.

3. Soluții existente

OpenWeather

Similar cu lucrarea de fata, exista sisteme care pun la dispoziție date despre starea vremii si despre calitatea aerului. Platforma OpenWeather, a aerului API a fost folosit pentru obținerea datelor, are propria pagina web unde prezinta aceste informații. Aceștia prezinta datele afișate pe o harta care își schimbă culoare in funcție de parametrul pe care utilizatorul își dorește sa îl vizualizeze: temperatura, presiune, viteza vântului, nori, precipitații. Un exemplu de harta care prezinta date despre temperatura se poate vedea mai jos.

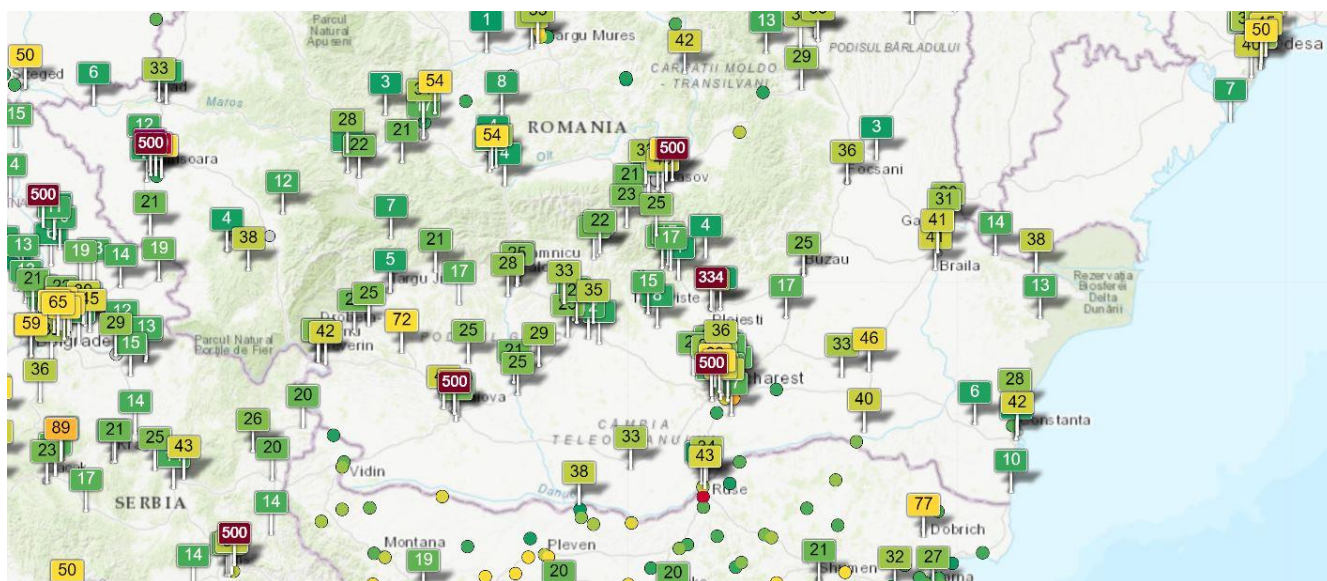


Figură 3.1

Platforma nu dispune si de o reprezentare vizuala a datelor legate de calitatea aerului.

AQICN

O prezentare vizuala mai buna este oferita de platforma Aqicn, care marchează pe harta poziția și valoarea calității aerului înregistrată de o anumită stație locală. Aceștia oferă și o predicție a acestor valori pentru câteva zile.



Figură 3.2

O prezentare a predicției calității poate fi observată mai jos.



Figură 3.3

Putem observa ca este prezentata o valoare estimativa a poluantului PM2.5 pentru următoarele 4 zile.

4. Soluția propusă

4.1. Tehnologii folosite

În realizarea acestui proiect au fost folosite mai multe tehnologii și medii de dezvoltare. Fiind folosite mai multe limbaje de programare (Java, Python, C), pentru fiecare a fost necesar alt mediu de dezvoltare. Pentru realizarea codului principal al aplicației, dezvoltată cu limbajul Java, a fost folosit mediul de dezvoltare IntelliJ IDEA dezvoltat de JetBrains. Pentru antrenarea modelului de regresie, folosit în predicția schimbării cantităților de poluanți, a fost utilizat Spyder, un mediu de dezvoltare open-source care vine cu mai multe pachete utile instalate precum: NumPy, SciPy, Matplotlib, pandas, etc. Codul utilizat în controlul senzorilor cu ajutorul plăcii Arduino Uno a fost scris și încărcat pe microcontroler folosind Arduino IDE. Alte tehnologii necesare în realizarea proiectului vor fi descrise mai detaliat în cele ce urmează.

4.1.1. OpenWeather API

OpenWeather este o platformă ce pune la dispoziție o multitudine de unelte utile, care pot fi folosite pentru monitorizarea calității aerului dar nu numai. Platforma oferă de asemenea informații despre vreme, starea drumurilor, alerte meteo, intensitatea UV, etc. Platforma oferă date despre peste 200.000 orașe, acestea fiind colectate și procesate din mai multe surse precum sateliți, radar și spații meteo locale.

În această lucrare sunt folosite două API-uri: unul de la care colectăm date despre stațiile meteo dintr-o anumită regiune, și un alt API care oferă informații despre calitatea aerului la o anumită stație. Utilizarea detaliată a acestor servicii va fi detaliată în capitolul 4.2.

4.1.2. Java, JavaFX

Java

Aplicația este realizată folosind limbajul de programare Java, un limbaj dezvoltat la începutul anilor '90 de către Sun Microsystems. Limbajul este unul puternic tipizat, orientat pe obiecte. La descărcarea Java utilizatorul va primi Java Runtime Environment (JRE). Acest pachet conține Java Virtual Machine (JVM), clasele de bază și bibliotecile care pot fi folosite, fiind tot ceea ce este necesar pentru a rula aplicația Java. [4]

JRE nu vine si cu uneltele necesare creării de aplicații, unelte care fac parte din Java Development Kit (JDK). Acest pachet conține resurse necesare dezvoltării aplicațiilor precum o mașina virtuala privata (JVM), un compilator (javac), un arhivator (jar), un generator de documentație (javadoc), etc. [5]

JavaFX

Interfața aplicației este construita folosind JavaFX, un set de unelte complet, folosit pentru dezvoltarea aplicațiilor complexe. Aspectul aplicațiilor poate fi modificat si adaptat ușor la cerințele proiectului folosind Cascading Style Sheets (CSS) pentru controlul stilului elementelor de UI.

JavaFX 2.2 si versiunile mai noi sunt integrate complet in Java SE 7 Runtime Environment (JRE) si in Java Development Kit (JDK). Pentru ca JDK-ul este disponibil pentru toate platformele desktop ((Windows, Mac OS X, and Linux), aplicațiile care folosesc JavaFX sunt compatibile pe mai multe platforme. Oracle asigura lansarea sincronizata a update-urilor pentru toate platformele si oferă un program de mentenanță pentru companiile care folosesc JavaFX. [6]

4.1.3. Python

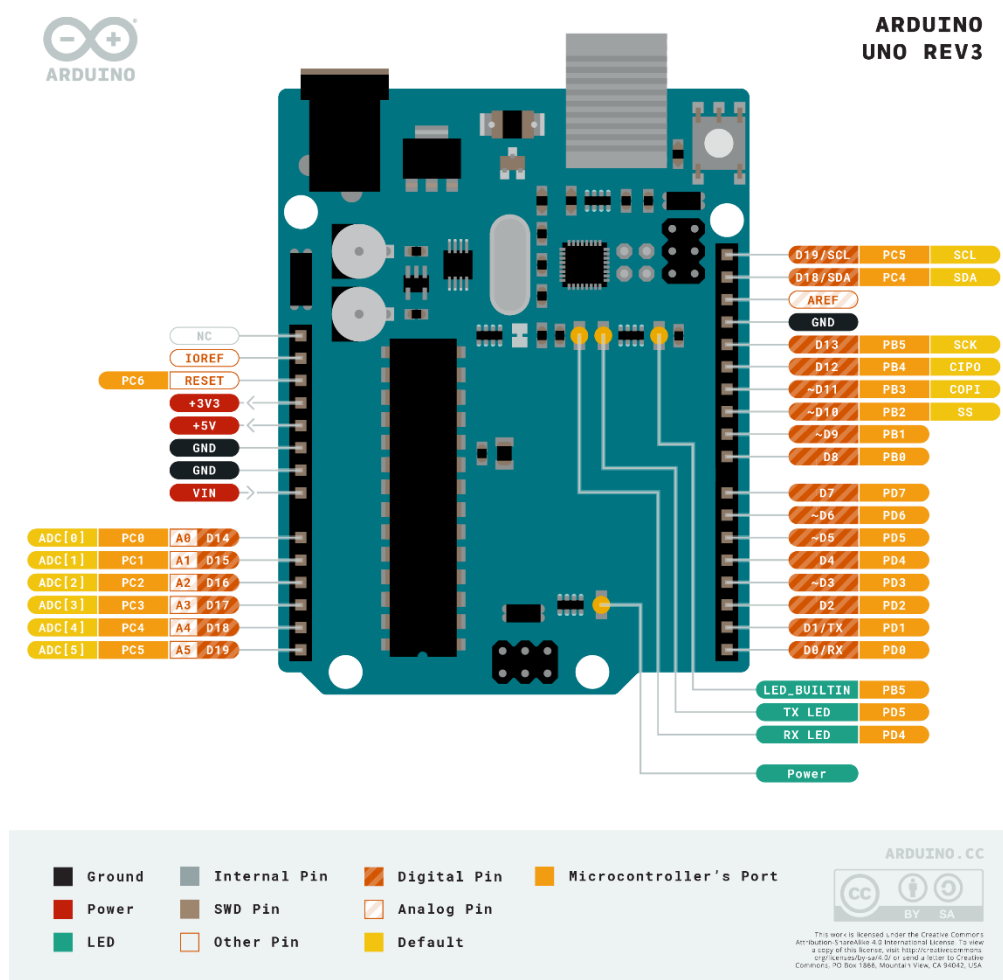
Aplicația prezinta si opțiunea de a face o predicție asupra poluanților din atmosfera. Pentru ca aceasta funcționalitate sa fie posibila, a fost necesara antrenarea unui model de regresie polinomiala, realizat cu ajutorul limbajului de programare Python si a bibliotecii Scikit-learn.

Python este un limbaj de programare dinamic, multi-paradigma, creat in 1989 de programatorul olandez Guido van Rossum. Limbajul pune accentul pe simplitatea si aspectul curat al codului, oferind posibilitatea de a exprima o idee intr-un mod clar si concis. Limbajul poate fi folosit si ca limbaj orientat pe obiecte, dar permite si programarea imperativa, funcționala sau procedurala. [7]

Scikit-learn este o biblioteca open-source care oferă algoritmi ce pot fi folosiți in învățarea supervizata si nesupervizata, procesarea datelor, si evaluarea rezultatelor. In acest proiect a fost folosit un algoritm de regresie polinomiala pentru predicția cantității diversilor poluanți din atmosfera in următoarea ora, folosind datele despre concentrațiile curente si viteza vântului. [8]

4.1.4. Arduino si senzorii utilizați

Pentru colectarea datelor despre calitatea aerului si alte date meteo cum ar fi temperatura, umiditate si presiune, a fost folosit placa de dezvoltare Arduino UNO împreuna cu senzorii necesari. Arduino UNO are la baza microcontrolerul ATmega328P, care dispune de 14 pini digitali (intrare\ieșire), 6 intrări analogice, având frecventa reglata de un rezonator ceramic de 16MHz. Tensiunea oferita de pini este de 5V, iar curentul de 20 mA, alimentarea plăcii fiind posibila prin conectorul USB sau de la o alta sursa externa care este acceptata de regulatorul de tensiune inclus, intre 5V si 12V. [9]



Figură 4.1

In colectarea datelor au fost folosiți următorii senzori: MQ-137, MQ-5, BMP280, THD11.

MQ-137 si MQ-5

Pentru detecția gazelor din aer sunt folosiți senzorii din seria MQ care oferă o soluție low-cost si fiabila. Senzorii au in componenta lor un element rezistiv care se încălzește si un senzor electrochimic. Elementul de încălzire este necesar pentru a aduce suprafața reactiva a senzorului, de obicei un oxid metalic, la o temperatura ideala detecției. La reacția cu gazul rezistența senzorului variază, aceasta variație fiind dependenta de concentrația gazului din atmosfera, poate fi măsurata si astfel determinata concentrația.




Figură 4.2

Senzorii MQ trebuie folosiți in medii închise si la temperaturi care sa nu fie prea mari sau prea mici. Pentru ca elementul de încălzire este ținut la o temperatura constanta fără a se tine cont de temperatura ambientala, daca este folosit in medii cu temperaturi prea mari sau prea mici, măsurătorile pot fi eronate. Pentru ca măsurătorile sa fie cat mai corecte, un timp de preîncălzire este necesar. Acest timp variază in funcție de modelul senzorului. [10]

DHT11

Senzorul DHT11 este folosit pentru măsurarea temperaturii și a umidității. Acesta are inclus un microcontroler pe 8bit care este folosit în transmiterea serială a datelor măsurate, fiind deja calibrat este ușor de folosit, în cazul de față, cu un microcontroler precum Arduino. Senzorul poate măsura temperaturi între 0°C și 50°C, și umiditate între 20% și 90% cu o acuratețe de $\pm 1^\circ\text{C}$ și $\pm 1\%$. Deoarece este un senzor cu un preț redus acuratețea datelor nu va fi foarte ridicată, iar datele de la senzor pot fi citite la fiecare 2 secunde, spre deosebire de DHT22, dar care are dimensiuni mai mari și este mai scump.

Pentru măsurarea umidității și temperaturii, este folosit un senzor capacitiv de umiditate și un termistor pentru măsurarea temperaturii. Este important de reținut faptul că DHT11 măsoară umiditatea relativă, reprezentând cantitatea de vapori din aer în comparație cu starea sa de saturație, aerul saturat având o umiditate relativă de 100%, iar cel uscat de 0%. Punctul de saturație se schimbă cu temperatura aerului, aerul rece putând conține mai puțini vapori de apă decât cel cald. [11]



Figură 4.3

	Condiții	Minim	Recomandat	Maxim
Tensiunea de alimentare		3V DC	5V DC	5.5V DC
Curent	Măsurare	0.5 mA		2.5 mA
	Mediu	0.2 mA		1 mA
	Standby	100 uA		150 uA
Perioada de măsurare		1 secunda		

Tabel 4.1

BMP280

Pentru măsurarea presiunii atmosferice se folosește senzorul BMP280, un senzor compact, de mici dimensiuni, și cu un consum scăzut. Senzorul poate măsura presiunea și temperatura cu o acuratețe bună, iar pentru ca presiunea atmosferică se schimbă în funcție de înălțimea la care este efectuată măsurătoarea, senzorul poate fi folosit și ca altimetru. [12]

Comunicarea cu Arduino se realizează prin protocolul I2C.

4.2. Aplicația

Prezentarea generala

Aplicația realizată oferă un mediu în care datele meteo și cele legate de calitatea aerului pot fi analizate și observate într-o interfață simplă și ușor de folosit. În centrul interfeței se afla un panou unde acestea sunt prezentate vizual, stațiile meteo fiind reprezentate de cercuri colorate în funcție de valoarea AQI-ului calculat, distribuția lor respectând așezarea pe hartă. Fiecare stație meteo poate fi analizată în detaliu, într-o fereastră ce se deschide separat de cea principală, unde sunt afișate: temperatura, umiditatea, viteza și direcția vântului, cantitatea poluanților la momentul actual și o predicție a acestor valori în următoarea oră și o listă cu posibilele surse de poluare. Aplicația prezintă și un meniu de ajutor în care utilizatorul poate găsi informații relevante despre modul de operare al funcțiilor de bază.

Pe lângă aceste funcționalități de bază, meniurile suplimentare oferă posibilitatea de a folosi aplicația pentru salvarea automată a datelor la un interval fix de o oră, salvarea manuală și încărcarea acestora din memorie, dar și o interfață pentru a observa datele colectate de senzorii conectați la placa arduino.

Folosind un API public, care necesită o cheie de acces, aplicația oferă posibilitatea de a schimba cheia de bază salvată în memorie, utilizatorul putând astfel folosi un plan diferit de cel gratuit pus la dispoziție de platforma OpenWeather. Planul de bază folosit în mod implicit are câteva limitări, cum ar fi un număr de doar 60 apeluri pe oră și o disponibilitate a serviciilor de 95% din timp.

Colectarea datelor

Pentru a putea analiza starea aerului din zona dorită, este necesară cunoașterea coordonatelor, care trebuie completate în câșuța de text cu numele „Coordinates”. Coordonatele trebuie introduse în formatul corect, folosit la efectuarea cererii către API, și anume: longitudine stânga, latitudine jos, longitudine dreapta, latitudine sus, separate prin virgulă, aceste valori formând un dreptunghi care delimitează zona geografică în care vor fi căutate stații meteorologice. Putând fi introduse orice valori, este necesar un pas de validare care va asigura corectitudinea datelor introduse. Se vor verifica astfel intervalele din care fac parte coordonatele, latitudinea putând fi în intervalul $[-90, 90]$, iar longitudinea în intervalul $[-180, 180]$, dar și faptul că suprafața determinată de aceste valori nu depășește 5 deg^2 , aceasta fiind o limitare a serviciului pus la dispoziție de platforma OpenWeather. Înainte de validarea datelor se efectuează preprocesarea lor, eliminând spațiile nedorite și separând valorile folosind delimitatorul virgulă. Orice abatere de la formatul corect va duce la neefectuarea cererii către platformă și generarea unui mesaj de eroare care va informa utilizatorul cu privire la greșeala făcută. De exemplu introducerea a mai puțin sau mai mult de patru valori va genera mesajul de eroare „Coordinates are not complete !”, afișat într-o fereastră nouă.

Pentru a putea testa funcționalitatea aplicației mai ușor, în cazul în care nu se completează coordonatele dorite, se vor folosi valorile implicite: 24.41, 44.17, 26.90, 45.95, delimitând astfel zona de interes ca fiind una ce cuprinde localități precum Brașov, București, Făgăraș, etc.

După introducerea corectă a coordonatelor este necesară apăsarea butonului „Get Data”, care va duce la efectuarea unei serii de operații necesare pentru a afișa datele dorite.

În primul rând va fi apelat API-ul platformei OpenWeather pentru a primi datele legate de stațiile meteorologice din zona dorită. Datele vor avea în componenta lor o listă de stații meteorologice despre care se cunosc numele și coordonatele. Coordonatele sunt folosite pentru a efectua un alt apel, de data aceasta către un alt serviciu ce va oferi datele de interes și anume cele despre concentrațiile poluanților și starea vremii, ce vor fi stocate în clasa „Station”, o listă de astfel de clase fiind la rândul ei stocată în clasa „StationMap”.

Afișarea datelor

În al doilea rând se va realiza procesul de afișare pe ecran al stațiilor, acestea fiind reprezentate de un cerc colorat diferit în funcție de calitatea aerului raportată în acea zonă și de o linie neagră care va avea lungimea și orientarea diferită în funcție de viteza respectiv direcția vântului. Lungimea liniilor este relativă pentru fiecare set de date, acestea fiind normate la cea mai mare viteză găsită în momentul colectării datelor, cea mai lungă linie pe ecran având maxim 40 pixeli. Pentru a putea face acest lucru, prima dată vor fi șterse de pe ecran datele afișate anterior, în cazul în care acestea există, apoi pentru ca spațiul de afișare este un pătrat cu latura de 400 px, iar poziția stațiilor este dată de coordonate sferice, trebuie folosită o funcție de conversie a poziției.

```
public Point2D convertToPoint2DInBound(CoordBoundingBox boundingBox)
{
    double OFFSET_WIDTH = 0.1 * Config.DATA_PANE_WIDTH;
    double OFFSET_HEIGHT = 0.1 * Config.DATA_PANE_HEIGHT;

    double distX = Math.abs(lon - boundingBox.getMinLon());
    double distY = Math.abs(lat - boundingBox.getMinLat());

    double maxDistX = Math.abs(boundingBox.getMaxLon() - boundingBox.getMinLon());
    double maxDistY = Math.abs(boundingBox.getMaxLat() - boundingBox.getMinLat());

    double distXNormalized = distX / maxDistX;
    double distYNormalized = distY / maxDistY;
```


În figura de mai sus se pot observa culorile diferite date de calitatea aerului în jurul stației respective și liniile folosite pentru reprezentarea vântului.

Procesarea datelor

După colectarea și afișarea datelor, pentru a realiza o analiză a acestora este necesară apăsarea butonului „Calculate”, care va efectua apelul funcției „calculate”. Aceasta, pe lângă validările necesare, va efectua trei operații: găsirea posibilelor surse de poluare, aproximarea modificării cantităților de poluanți în următoarea oră și sortarea în funcție de nivelul de poluare a posibilelor surse.

```
public static void calculate()
{
    areCalculationDone = true;

    System.out.println("Calculating...");

    if(stationsMap == null) {
        System.out.println("No data to calculate: null stationsMap");
        return;
    }

    if(stationsMap.getStations() == null) {
        System.out.println("No data to calculate: null stationsMap.getStations()");
        return;
    }

    for(Station station : stationsMap.getStations()){
        station.findWindSource(stationsMap);
        station.componentChange();
        station.sortPossibleSources();
    }
}
```

Prima funcție apelată, „findWindSource” are scopul de a găsi stațiile spre care suflă vântul de la stația actuală. Datorită dimensiunilor scăzute, particulele și moleculele de gaz ce constituie poluanții pot fi transportați de vânt pe distanțe care variază între zeci de metri și mii de kilometri, dar pentru aplicația de față se vor lua în considerare doar stațiile aflate pe o rază de 50Km, crescând astfel șansa ca poluarea măsurată la stația respectivă să fie influențată de stația de unde se efectuează căutarea. Pentru a găsi aceste stații trebuie determinat prima dată dacă direcția vântului este în treptată către o altă stație, pentru asta se va folosi o funcție ajutătoare denumită „lookAt” care primește ca parametrii cele două puncte și

unghiul dat de direcția vântului. Funcția va întoarce un număr între 0 și 180, reprezentând unghiul format între o dreaptă trasată între cele două puncte folosite și o dreaptă determinată de direcția vântului.

După găsirea posibilelor surse de poluare, pentru a le putea afișa într-o ordine relevantă, acestea vor fi sortate în funcție de valoarea AQI-ului, mărime ce indică gradul de poluare. Pentru calculul acestei valori se folosesc concentrațiile poluanților înregistrați, și punctele critice ale acestor concentrații, așa cum este descris mai jos.

$$I = \frac{I_{high} - I_{low}}{C_{high} - C_{low}} (C - C_{low}) + I_{low}$$

Unde:

I - indexul pentru calitatea aerului

C - concentrația de poluant

C_{low} - punctul critic al concentrației $\leq C$

C_{high} - punctul critic al concentrației $\geq C$

I_{low} - punctul critic al indexului corespunzător lui C_{low}

I_{high} - punctul critic al indexului corespunzător lui C_{high}

Valorile punctelor critice pot fi regăsite în tabelul de mai jos, oferit de Biroul pentru Calitatea Aerului (US EPA) [13]

O3 (ppb)	PM2.5 (µg/m3)	PM10 (µg/m3)	CO (ppm)	SO2 (ppb)	NO2 (ppb)	AQI	AQI
Clow – Chigh (avg)	Clow – Chigh (avg)	Clow – Chigh (avg)	Clow – Chigh (avg)	Clow – Chigh (avg)	Clow – Chigh (avg)	Ilow – Ihigh	Categorie
-	0.0-12.0	0-54	0.0-4.4	0-35	0-53	0-50	Bun
-	12.1-35.4	55-154	4.5-9.4	36-75	54-100	51-100	Moderat
125-164	35.5-55.4	155-254	9.5-12.4	76-185	101-360	101-150	Nesănătos pentru grupurile sensibile
165-204	55.5-150.4	255-354	12.5-15.4	186-304	361-649	151-200	Nesănătos
205-404	150.5-250.4	355-424	15.5-30.4	305-604	650-1249	201-300	Foarte nesănătos
405-504	250.5-350.4	425-504	30.5-40.4	605-804	1250-1649	301-400	Periculos
505-604	350.5-500.4	505-604	40.5-50.4	805-1004	1650-2049	401-500	

Tabel 4.2

Dacă sunt măsurați mai mulți poluanți, pentru a determina AQI-ul se va calcula valoarea I pentru fiecare poluant și se va alege maximumul dintre aceste valori. În proiectul prezentat se va calcula valoarea I pentru 5 poluanți, și anume: Pm 2.5, Pm 10, CO, SO2, NO2. Această valoare se va afișa într-o interfață separată, dedicată stației pentru care a fost calculată. Pentru realizarea acestei operații se va folosi o funcție specială.

```
public static int calculateAQI(Components components)
{
    int aqi[] = {
        pm2_5AQI(components.getPm2_5()),
        pm10AQI(components.getPm10()),
        coAQI(components.getCo()),
        so2AQI(components.getSo2()),
        no2AQI(components.getNo2())
    };
}
```



```

        Arrays.sort(aqi);

        return aqi[4];
    }

```

Funcția prezentată mai sus, realizează calculul valorii AQI maxime, calculând pentru fiecare poluant valoarea I. Aceste valori sunt stocate într-un vector care este sortat pentru a obține la sfârșitul lui cel mai mare element. Această operație este rapidă, algoritmul de sortare implementat în Java fiind unul rapid (cu o complexitate de timp de $O(n \log n)$), dar și pentru că sunt foarte puține elemente.

Pentru a putea realiza o predicție asupra concentrațiilor poluanților în următoarea oră se va folosi un model de regresie polinomială. Datele necesare antrenării modelului, deoarece nu au fost puse la dispoziție de platforma OpenWeather în mod gratuit, a fost necesară implementarea unui mod de colectare automată. În meniul „Tools” al interfeței principale poate fi regăsit butonul „Start auto data collect” care va duce la pornirea procesului de colectare a datelor. Programul va porni o funcție pe un thread separat de cel principal, unde la un interval de o oră va salva datele primite prin apelul API-ului, într-un fișier de tipul JSON, cu numele de tipul: „map_file_06_06_2022_18_12_43.json”, reprezentând data și ora la care a fost salvat fișierul.

La închiderea procesului de colectare aplicația va genera un fișier text în care vor fi notate câteva statistici despre acesta. De exemplu, în procesul de colectare a datelor folosite în aplicația prezentată fișierul generat a conținut datele de mai jos.

```

AppMetrics:

totalAPICalls = 1501

totalFilesSaved = 79


startTime = Wed May 25 22:51:27 EEST 2022

endTime = Sun May 29 05:44:24 EEST 2022

totalHoursRunning = 78.0

```

După cum poate fi observat, datele au fost adunate pe parcursul a 78 de ore, începând la ora 22:51 pe data de 25 Mai și a fost oprit pe data de 29 Mai la ora 05:44. Au fost efectuate 1501 apeluri ale serviciului și au fost salvate 79 de fișiere. După procesarea acestor fișiere au fost obținute 1279 puncte ce pot fi folosite în antrenarea modelului. Datele relevante au fost viteza vântului și concentrația poluanților, aceste două valori având o relație invers proporțională, când viteza vântului crește, concentrația poluanților scade.




Figură 4.5

În acest grafic se poate observa relația dintre concentrația poluantului PM10 și viteza vântului, pentru București în intervalul 20 Aprilie ora 15:08 și 23 Aprilie ora 16:09. În această perioadă viteza vântului a atins un maxim de 8.75 Km/h, iar concentrația de PM10 un maxim de 51.02 $\mu\text{g}/\text{m}^3$.

Pentru a ajunge la un model care să aproximeze cât mai bine modul în care aceste valori se vor schimba în următoarea oră, valorile colectate anterior se vor procesa, aducându-le în formatul necesar. Pentru antrenarea modelului sunt necesare date de intrare și de ieșire. Datele de intrare vor fi viteza vântului și concentrația curentă de poluant, iar cele de ieșire, concentrația de poluant ora următoare.


Regresia se va realiza folosind bibliotecile specializate din python, și anume „sklearn” pentru modelul regresiei și „pandas” pentru procesarea datelor.

Un prim pas în analizarea datelor colectate a fost cel de a reprezenta grafic cantitatea medie de poluant asociată unei anumite viteze a vântului. Se poate observa în graficul de mai jos cum cantitatea medie de poluant scade atunci când viteza vântului crește.



Figură 4.6

În încercarea de a aproxima această relație cât mai bine, vom încerca realizarea regresiei polinomiale pe ecuații de grade diferite, începând cu gradul 0 până la gradul 10, și se va calcula RMSE (Root Mean Square Error), mărime ce ne va ajuta să determinăm care dintre modele este cel mai bun. Pentru fiecare grad, se va calcula eroarea pătratică medie, pentru fiecare dintre cele 8 componente pe care dorim să le aproximăm, făcând o medie a acestor valori. După evaluarea tuturor modelelor putem reprezenta grafic valorile obținute. În cazul de față cea mai bună valoare a fost obținută pentru gradul 4.



Figură 4.7

Pentru a putea folosi acest model in java, trebuie sa cunoaştem coeficienţii determinaţi, care sa poată fi integraţi într-o funcţie de predicţie. Coeficienţii au fost introduşi in cod in felul următor (pentru a nu încarcă pagina este prezentat un singur exemplu, pentru PM10).

```
private static double pm10Coef[] = {0.0,-
0.5723140624957793,0.7578966461767227,0.23357257005112653,0.17097189146586853,0.009688017571
218932,-0.039286179429026694,-0.03050615634049534,-
0.011457938774469404,0.0002895032453965351,0.0019571788782336034,0.0018496234849557083,0.000
9939104352038905,0.00014378949027886375,-1.0111364551267561e-05};

private static double pm10Intercept = 0.7099155843068061;
```

Iar funcţia de predicţie este următoarea:

```
public static double predictPm10(double currentWind, double currentPm10)
{
    double a = currentWind;
    double b = currentPm10;

    double terms[] = Utils.genTerms(a, b, 4);

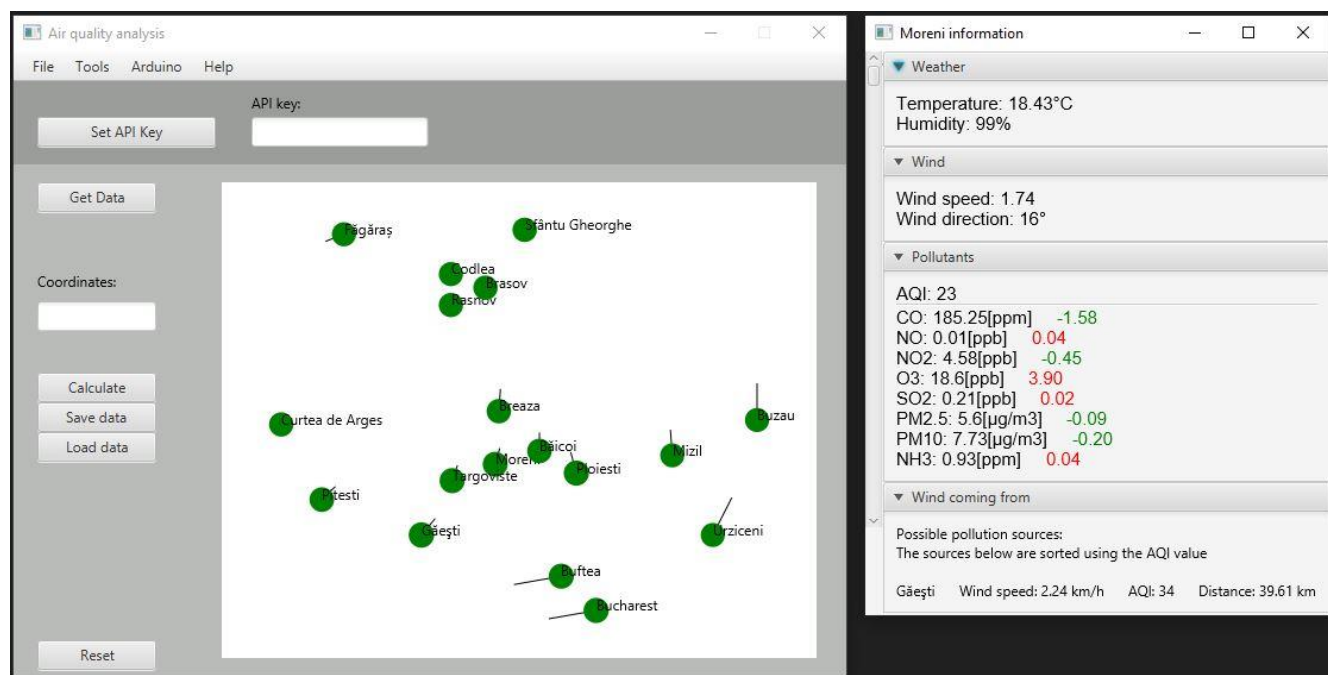
    double val = 0;
    for(int i = 0; i < 15; i++)
    {
        val += pm10Coef[i]*terms[i];
    }
}
```

```

    return val + pm10Intercept;
}

```

După ce toate operațiile de procesare a datelor sunt finalizate, utilizatorul poate selecta o stație dorită, moment în care se va deschide o fereastră nouă, cu datele relevante.



Figură 4.8

Fereastră din dreapta oferă informații detaliate despre stație, interfața fiind împărțită în segmente ce pot fi strânse, în cazul în care utilizatorul nu dorește să încarce spațiul cu acestea. Primele informații sunt Temperatura și umiditatea, unde se poate observa o temperatură nu foarte ridicată, și o umiditate de 99% datorată precipitațiilor din momentul colectării datelor. Următorul segment prezintă condițiile vântului, anume viteza și direcția în grade, 0 fiind Nord iar 180 Sud. Al treilea segment conține cantitățile de poluanți curenți și predicția acestora în ora următoare, valorile fiind colorate sugestiv: verde în cazul în care concentrația scade, o concentrație scăzută fiind un lucru bun și roșu în cazul în care aceasta crește. Înainte de valorile concentrațiilor este scris AQI-ul, o valoare de bază în analiza calității aerului. Ultimul segment al interfeței prezintă datele despre posibila sursă de poluare, fiind listate localitățile cele mai apropiate, unde vântul este direcționat spre localitatea curentă. Acestea sunt ordonate descrescător în funcție de valoarea AQI-ului, deoarece dacă acesta este mare, șansele ca o cantitate de poluare care poate fi transportată cresc, calitatea aerului în jurul stației actuale putând scădea.

Conectarea la API

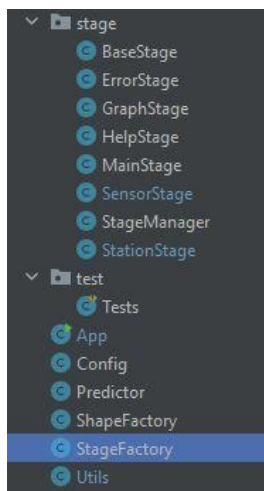
Folosind un serviciu care prezinta funcționalități ce pot necesita efectuarea unei plăți, acesta necesita crearea unui cont. In urma acestei operații utilizatorul va primi o cheie de acces al API-ului. Aplicația realizata stochează in memorie cheia care oferă funcționalitățile de baza într-o clasa speciala numita „Config”. Aceasta clasa conține date despre căile către directoarele folosite la salvarea fișierelor, dimensiuni standard ale interfețelor, si cheia de acces către API.

In cazul in care utilizatorul dorește folosirea unui alt plan fata de cel standard oferit, cheia de acces poate fi schimbata folosind câmpul „API key”, in care o noua cheie poate fi introdusa, iar apăsarea butonului „Set API key” va realiza salvarea unei noi chei. In cazul in care câmpul este gol, dar se apasă butonul, cheia va reveni la starea inițiala.

Detalii relevante

Una din funcționalitățile utile ale aplicației este închiderea recursiva a ferestrelor deschise. De exemplu, daca utilizatorul deschide mai multe ferestre care prezinta informații despre stații, in momentul închiderii aplicației acestea vor fi închise automat. Fără aceasta operație, programul nu ar termina execuția pana când toate ferestrele nu ar fi închise, lucru care ar crea disconfort in utilizare.

In dezvoltarea aplicației, codul a fost structurat si împărțit in clase si pachete dedicate funcțiilor necesare. Fiecare clasa creata îndeplinind atribuții cat mai clare, iar clasele cu funcții asemănătoare au fost grupate in pachete cu nume sugestive. De exemplu pentru afișarea diferitelor ferestre au fost create mai multe clase, fiecare fiind specializata in afișarea unui singur tip de fereastră. Pentru a crea instanțe a acestor clase a fost folosit design pattern-ul „factory”, folosind clasa „StageFactory” care construiește clase precum „ErrorStage”, „MainStage”, etc.



Figură 4.9

4.3. Senzorii

Prezentare generala

Pentru a putea colecta date din locația exactă a utilizatorului se vor folosi patru senzori conectați la o placă Arduino UNO. Senzori vor putea colecta date despre temperatura, umiditate, presiune și concentrația anumitor gaze care, dacă se afla într-o concentrație prea mare în aerul respirat pot scădea calitatea acestuia. Dintre senzorii folosiți, doi dintre aceștia sunt capabili să măsoare temperatura ambientală, ceea ce poate fi util, servind ca o măsură de siguranță, astfel dacă un senzor nu funcționează corect se va putea observa o diferență destul de mare între cele două temperaturi raportate. Umiditatea este o altă mărime relevantă pentru confort, o valoare adecvată aflându-se în intervalul 40% - 60%.

Mărimile măsurate

Măsurând temperatura și umiditatea relativă putem calcula o nouă mărime importantă, și anume indexul de căldură. Aceasta mărime are rolul de a oferi o descriere mai bună a modului în care temperatura este resimțită de o persoană (se consideră o valoare a temperaturii măsurate într-o zonă umbră). Deoarece oamenii folosesc ca mecanism de răcire transpirația, o umiditate suficient de mare poate încetini procesul de evaporare a apei (transpirației), ducând astfel la senzația de supraîncălzire. Indexul de căldură poate fi resimțit diferit de la persoană la persoană, fiind influențat de diverși factori cum ar fi condiția fizică, nivelul de hidratare, etc. În proiectul prezentat, această mărime este calculată în mod automat folosind o bibliotecă specializată pentru senzorul DHT11, apelând funcția prezentată mai jos. Ultimul parametru al funcției poate lua valoarea *true* sau *false*, indicând dacă valorile vor fi în grade Fahrenheit sau Celsius.

```
float heatIndex_dht = dht.computeHeatIndex(temperature_dht, humidity_dht, false);
```

Mai jos poate fi observat un tabel cu valorile posibile împărțite in patru categorii de risc, acestea fiind foarte importante deoarece un index ridicat poate avea efecte fatale.

NOAA national weather service: heat index

Temperature Relative humidity	80 °F (27 °C)	82 °F (28 °C)	84 °F (29 °C)	86 °F (30 °C)	88 °F (31 °C)	90 °F (32 °C)	92 °F (33 °C)	94 °F (34 °C)	96 °F (36 °C)	98 °F (37 °C)	100 °F (38 °C)	102 °F (39 °C)	104 °F (40 °C)	106 °F (41 °C)	108 °F (42 °C)	110 °F (43 °C)
40%	80 °F (27 °C)	81 °F (27 °C)	83 °F (28 °C)	85 °F (29 °C)	88 °F (31 °C)	91 °F (33 °C)	94 °F (34 °C)	97 °F (36 °C)	101 °F (38 °C)	105 °F (41 °C)	109 °F (43 °C)	114 °F (46 °C)	119 °F (48 °C)	124 °F (51 °C)	130 °F (54 °C)	136 °F (58 °C)
45%	80 °F (27 °C)	82 °F (28 °C)	84 °F (29 °C)	87 °F (31 °C)	89 °F (32 °C)	93 °F (34 °C)	96 °F (36 °C)	100 °F (38 °C)	104 °F (40 °C)	109 °F (43 °C)	114 °F (46 °C)	119 °F (48 °C)	124 °F (51 °C)	130 °F (54 °C)	137 °F (58 °C)	
50%	81 °F (27 °C)	83 °F (28 °C)	85 °F (29 °C)	88 °F (31 °C)	91 °F (33 °C)	95 °F (35 °C)	99 °F (37 °C)	103 °F (39 °C)	108 °F (42 °C)	113 °F (45 °C)	118 °F (48 °C)	124 °F (51 °C)	131 °F (55 °C)	137 °F (58 °C)		
55%	81 °F (27 °C)	84 °F (29 °C)	86 °F (30 °C)	89 °F (32 °C)	93 °F (34 °C)	97 °F (36 °C)	101 °F (38 °C)	106 °F (41 °C)	112 °F (44 °C)	117 °F (47 °C)	124 °F (51 °C)	130 °F (54 °C)	137 °F (58 °C)			
60%	82 °F (28 °C)	84 °F (29 °C)	88 °F (31 °C)	91 °F (33 °C)	95 °F (35 °C)	100 °F (38 °C)	105 °F (41 °C)	110 °F (43 °C)	116 °F (47 °C)	123 °F (51 °C)	129 °F (54 °C)	137 °F (58 °C)				
65%	82 °F (28 °C)	85 °F (29 °C)	89 °F (32 °C)	93 °F (34 °C)	98 °F (37 °C)	103 °F (39 °C)	108 °F (42 °C)	114 °F (46 °C)	121 °F (49 °C)	128 °F (53 °C)	136 °F (58 °C)					
70%	83 °F (29 °C)	86 °F (30 °C)	90 °F (32 °C)	95 °F (35 °C)	100 °F (38 °C)	105 °F (41 °C)	112 °F (44 °C)	119 °F (48 °C)	126 °F (52 °C)	134 °F (57 °C)						
75%	84 °F (29 °C)	88 °F (31 °C)	92 °F (33 °C)	97 °F (36 °C)	103 °F (39 °C)	109 °F (43 °C)	116 °F (47 °C)	124 °F (51 °C)	132 °F (56 °C)							
80%	84 °F (29 °C)	89 °F (32 °C)	94 °F (34 °C)	100 °F (38 °C)	106 °F (41 °C)	113 °F (45 °C)	121 °F (49 °C)	129 °F (54 °C)								
85%	85 °F (29 °C)	90 °F (32 °C)	96 °F (36 °C)	102 °F (39 °C)	110 °F (43 °C)	117 °F (47 °C)	126 °F (52 °C)	135 °F (57 °C)								
90%	86 °F (30 °C)	91 °F (33 °C)	98 °F (37 °C)	105 °F (41 °C)	113 °F (45 °C)	122 °F (50 °C)	131 °F (55 °C)									
95%	86 °F (30 °C)	93 °F (34 °C)	100 °F (38 °C)	108 °F (42 °C)	117 °F (47 °C)	127 °F (53 °C)										
100%	87 °F (31 °C)	95 °F (35 °C)	103 °F (39 °C)	112 °F (44 °C)	121 °F (49 °C)	132 °F (56 °C)										

Key to colors: Caution Extreme caution Danger Extreme danger

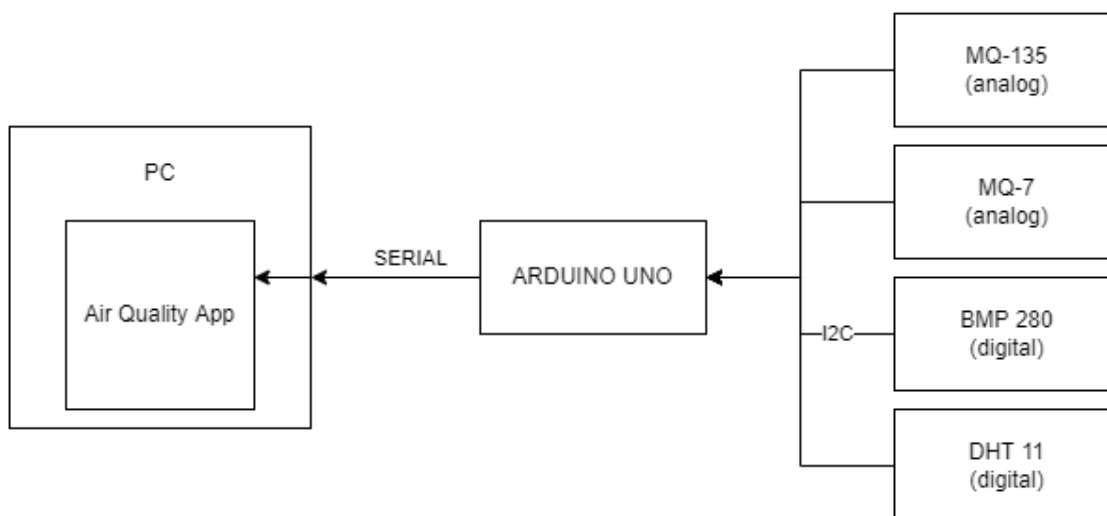
Figură 4.10

Senzorii MQ sunt folosiți pentru a măsura concentrația diverselor gaze din aer, precum monoxidul de carbon sau amoniacul, ambele fiind compuși toxici și foarte periculoși, efecte grave asupra sănătății. Concentrația acestora este direct dependentă de tensiunea măsurată la ieșirea senzorilor, rezistența internă a acestora fiind influențată de concentrația gazelor din jur. Deoarece senzorii MQ reprezintă o variantă mai puțin costisitoare, măsurătorile realizate nu vor putea fi perfecte, elementele interne fiind sensibile și la alte gaze din atmosfera.

Temperatura este măsurată folosind senzorii DHT11, dar și BMP280, putând astfel determina o valoare a temperaturii reale mai apropiată de cea adevărată. Pe lângă temperatura senzorul DHT11 este folosit pentru a măsura umiditatea relativă din aer, iar BMP280 pentru a măsura presiunea atmosferică.

Structura hardware

Senzorii sunt conectați la arduino folosind atât pini digitali cât și analogici. Valorile senzorilor MQ-7 și MQ-135 sunt citite folosind pini analogici A1 respectiv A0. Senzorul BMP280 comunica cu arduino folosind protocolul I2C, fiind astfel conectat la A4(SDA) și A5(SCL), iar senzorul DHT11 folosește un singur pin digital pentru transmiterea datelor, anume pinul D2. Mai jos poate fi observată schema bloc a proiectului. Toate datele sunt colectate folosind placa Arduino și sunt transmise mai departe către aplicația principală, urmând a fi citite folosind comunicarea serială și portul la care este conectat Arduino.



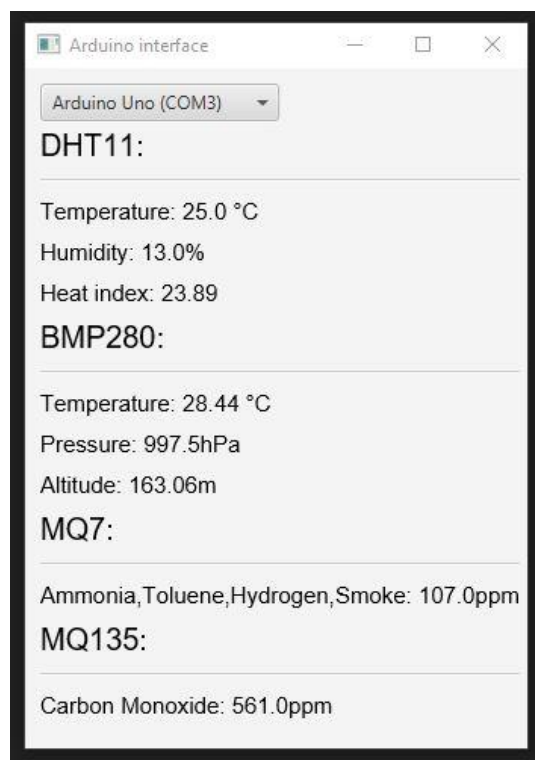
Figură 4.11

Interfața

Aplicația prezintă o interfață pentru a facilita conectarea cu placa și observarea activității senzorilor. Interfața poate fi accesată din meniul „Arduino” al interfeței principale, unde, dintr-un meniu „drop-down” se poate alege dispozitivul cu care să se stabilească conexiunea, în cazul de față dispozitivul poate fi doar o placă Arduino. Dacă nu este găsit un dispozitiv corespunzător, în meniul de selecție, va exista o singură opțiune cu numele „Nothing available on port”, altfel se va afișa numele corespunzător, de exemplu „Arduino Uno (COM3)”.

Interfața este împărțită în patru segmente, folosind linii orizontale, delimitând astfel o zonă pentru fiecare senzor. Deasupra fiecărei linii este numele senzorului, iar sub aceasta datele colectate de la respectivul dispozitiv. De exemplu, cum se poate observa și în figura, senzorul DHT11 oferă informații despre temperatura, umiditate, și valoarea indexului de căldură.

O problemă vizibilă în figura este diferența dintre temperatura măsurată de cei doi senzori, 25.0 °C și 28.44 °C. Această problemă poate apărea din cauza amplasării senzorilor, BMP280 fiind poziționat mai aproape de cei doi senzori MQ, care au în componența lor un element ce produce căldura, ducând astfel la o măsurare nu foarte precisă a temperaturii ambientale. Un alt factor care poate produce această eroare este izolarea mai slabă decât cea a senzorului DHT11. Pentru a remedia acest lucru senzorii MQ trebuie poziționați la o distanță suficient de mare de senzori de temperatura pentru a nu perturba colectarea datelor.



Figură 4.12

Comunicarea seriala

Pentru a putea primi și procesa datele de la Arduino, comunicarea cu acesta se realizează pe un thread separat. Acesta este folosit pentru a nu bloca aplicația principală. La fel ca funcționalitatea de colectare automată a datelor, comunicarea cu modulul fizic, care strânge date locale, se poate realiza în paralel cu activitatea desfășurată de utilizator în aplicația principală.

În primul rând utilizatorul trebuie să aleagă dispozitivul cu care vrea să se realizeze conexiunea. Pentru a face asta, este necesară selectarea din lista afișată la deschiderea ferestrei prezentate anterior, a dispozitivului Arduino. Programul va scana porturile și în cazul în care nu există dispozitive disponibile se va afișa mesajul „Nothing available on port”, altfel se afișează numele dispozitivelor disponibile.

Datele se vor trimite în format JSON, pentru a facilita citirea acestora și memorarea lor într-o clasă specializată.

5. Evaluarea rezultatelor

Pentru a evalua rezultatele predicției în ceea ce privește concentrațiile valorilor poluanților, se vor folosi datele înregistrate de aplicație în decursul a 25 de ore. Pentru strângerea acestor date a fost folosită funcționalitatea de colectare automată, iar rezultatele au fost salvate în format text.

Se vor analiza datele legate de concentrația de PM10 începând cu data de 25 Mai 2022, ora 22:51. Deoarece acest fișier conține și informații nedorite, precum înregistrări ale activității aplicației, este necesară preprocesarea lor, păstrând doar informația esențială. Se pot observa mai jos două fragmente din fișierul salvat, înainte respectiv după procesare:

Task GET DATA performed at: Wed May 25 22:51:28 EEST 2022

Setting coordinates...

bbox initialize with default data

Constructing the map...

Try to get stations data from API

Getting weather data...

TOTAL API CALLS: 19

Total TIME ELAPSED: 2223ms

Displaying data...

Clearing pane...

Calculating...

Moreni:25/05/2022,1.32,11.31,11.270602523435908

Breaza:25/05/2022,1.7,8.54,8.644055570432997

Băicoi:25/05/2022,1.51,8.28,8.312751948701058

Targoviste:25/05/2022,0.54,10.98,11.141379229560888

Ploiesti:25/05/2022,0.76,15.19,15.422923318263226

Găești:25/05/2022,1.08,11.94,11.89993099145064

Rasnov:25/05/2022,2.94,4.65,5.184915421023601

Bufta:25/05/2022,1.03,16.45,16.550537769071912

Mizil:25/05/2022,2.85,7.81,8.663561204585072

Brasov:25/05/2022,2.6,4.93,5.389502231481544

Pitesti:25/05/2022,1.0,11.27,11.227099458533369

Codlea:25/05/2022,2.34,3.53,3.8671141827694053
Curtea de Arges:25/05/2022,0.48,9.88,10.024058720193114
Bucharest:25/05/2022,1.03,20.52,20.62000784232191
Urziceni:25/05/2022,5.39,5.91,7.677970104908151
Sfântu Gheorghe:25/05/2022,1.68,2.79,3.19803751493941
Buzau:25/05/2022,4.66,6.48,8.244420376580958
Făgăraș:25/05/2022,2.34,5.08,5.46438307275092
Task SAVE DATA performed at: Wed May 25 22:51:58 EEST 2022
Saving data...
Saved file: src/main/resources/saves/map_file_25_05_2022_22_51_58.json

După preprocesare ajungând in formatul CSV (Comma-separated values) :

statie,data,vant,pm10,pm10_next
Moreni,25/05/2022,1.32,11.31,11.270602523435908
Breaza,25/05/2022,1.7,8.54,8.644055570432997
Băicoi,25/05/2022,1.51,8.28,8.312751948701058
Targoviste,25/05/2022,0.54,10.98,11.141379229560888
Ploiesti,25/05/2022,0.76,15.19,15.422923318263226
Găești,25/05/2022,1.08,11.94,11.89993099145064
Rasnov,25/05/2022,2.94,4.65,5.184915421023601
Buftea,25/05/2022,1.03,16.45,16.550537769071912
Mizil,25/05/2022,2.85,7.81,8.663561204585072
Brasov,25/05/2022,2.6,4.93,5.389502231481544
Pitesti,25/05/2022,1.0,11.27,11.227099458533369
Codlea,25/05/2022,2.34,3.53,3.8671141827694053
Curtea de Arges,25/05/2022,0.48,9.88,10.024058720193114
Bucharest,25/05/2022,1.03,20.52,20.62000784232191
Urziceni,25/05/2022,5.39,5.91,7.677970104908151
Sfântu Gheorghe,25/05/2022,1.68,2.79,3.19803751493941
Buzau,25/05/2022,4.66,6.48,8.244420376580958
Făgăraș,25/05/2022,2.34,5.08,5.46438307275092

In continuare datele vor fi analizate folosind limbajul de programare Python, iar cu ajutorul bibliotecilor specializate, se va calcula, pentru fiecare stație valoarea RMSE (Root Mean Square Error), între lista valorilor actuale si lista valorilor prezise, urmând ca la final, sa se calculeze o valoare medie ce tine cont de toate stațiile.

Programul va separa datele in așa fel încât sa fie transformate din formatul CVS in doua liste stocate in memoria programului, una cu valori reale, respectiv cu valori prezise. După efectuarea acestor operații rezultatele sunt afișate in formatul următor:

--- valorile RMSE pentru fiecare statie ---

Statia 0 : RMSE = 1.4918834467972628

Statia 1 : RMSE = 1.194369242147286

Statia 2 : RMSE = 0.9362335369247768

Statia 3 : RMSE = 1.751245492060721

Statia 4 : RMSE = 2.5285645631130578

Statia 5 : RMSE = 1.7452552921451268

Statia 6 : RMSE = 0.7970742159820576

Statia 7 : RMSE = 3.2498931769497283

Statia 8 : RMSE = 1.2793660681088979

Statia 9 : RMSE = 1.1441979366756425

Statia 10 : RMSE = 1.9154230419409046

Statia 11 : RMSE = 1.0976633378290621

Statia 12 : RMSE = 1.2254082002101536

Statia 13 : RMSE = 2.9055056637939707

Statia 14 : RMSE = 1.9746231967981436

Statia 15 : RMSE = 0.9673113950010251

Statia 16 : RMSE = 1.474289481978079


Statia 17 : RMSE = 1.3539396544997628

--- valoarea medie RMSE ---

Mean RMSE: 1.6129026079419808

Pentru a putea vizualiza mai ușor aceste rezultate se poate trasa graficul valorilor, pentru una dintre stații:

Valoarea concentrației PM10 reale și Valoarea concentrației PM10 prezise



Figură 5.1

Ținând cont de imprevizibilitatea condițiilor atmosferice și activității umane, factori care contribuie în mare măsură, în schimbarea cantităților de poluanți din atmosferă, rezultatele obținute sunt apropiate de cele reale, eroarea fiind una relativ mică.

6. Concluzii

În acest capitol se vor prezenta concluziile referitoare capitolelor prezentate mai sus, obiectivele proiectului, rezultatele obținute și posibile îmbunătățiri ce pot fi aduse pe viitor. Așa cum am prezentat de la început, scopul lucrării descrise a fost de a oferi o soluție în ceea ce privește informarea locuitorilor cu privire la calitatea aerului. Aceste informații pot fi utile oricărei persoane, indiferent de grupul de risc din care face parte, expunerea la poluare putând dauna sănătății oricui. Informațiile colectate și prezentate de aplicație sunt temperatura și umiditatea aerului (și indexul de căldură în ceea ce privește modulul fizic), viteza și direcția vântului, cantitate poluanților monitorizați de stațiile meteorologice folosite de platforma OpenWeather, și legăturile dintre orașe, prezentând cele mai apropiate orașe cu un grad de poluare ridicat care poate fi transportat de vânt către o zonă de interes.

În ceea ce privește dezvoltarea aplicației putem spune că scopul a fost atins, aceasta fiind dezvoltată și testată cu succes. Utilizatorului îi este pus la dispoziție un sistem capabil să colecteze date relevante despre starea vremii și calitatea aerului, în mod manual sau automat, această funcționalitate dovedindu-se utilă în momentul antrenării modelului de regresie, și să le prezinte într-un mod intuitiv. Aplicația dispune de o interfață simplă ce facilitează interacțiunea cu programul, și oferă o modalitate de a evalua datele în mod vizual, cum am văzut în capitolele anterioare, folosind culori și ferestre separate pentru a prezenta datele.

Modulul fizic al proiectului, ansamblul de senzori conectați la placa de dezvoltare arduino, reprezintă de asemenea o parte importantă a proiectului, aceasta fiind capabilă să colecteze date utile, dar care nu pot fi descoperite folosind doar API-ul public pus la dispoziție de platforma OpenWeather și folosit în tot parcursul lucrării. Senzorii oferă o evaluare locală a calității aerului, mai restrânsă și mai simplă decât cea oferită de rețeaua de stații meteorologice, dar importantă. Monitorizarea nivelului de monoxid de carbon (CO) din aerul ce ne înconjoară este extrem de importantă, expunerea chiar și pe termen scurt la o cantitate ce depășește un prag critic (de obicei de peste 200 ppm), putând fi nocivă.

Un aspect important este evaluarea rezultatelor obținute, pas descris în detaliu în capitolul anterior. Am putut observa că aplicația este capabilă să prezică schimbarea cantităților de poluanți considerați în această lucrare (CO, NO, NO₂, O₃, SO₂, PM_{2.5}, PM₁₀, NH₃). Data fiind starea imprevizibilă a condițiilor meteorologice și a factorilor umani precum traficul sau activitățile industriale, care influențează în mod drastic starea aerului, dar care nu pot fi observate folosind stațiile meteorologice puse la dispoziție, predicția schimbărilor în cantitatea de poluanți putând fi una nu foarte precisă. Cu toate acestea rezultatele obținute sunt apropiate de cele reale, oferind astfel, chiar dacă nu o valoare precisă, una suficient de bună pentru a putea aproxima calitatea aerului în următoarea oră. Urmărind această schimbare, utilizatorul poate lua decizii în ceea ce privește expunerea la aerul din exterior, decizii care pot duce la evitarea unor probleme de sănătate pe termen lung.

Având în vedere că datele folosite în antrenarea modelului de regresie au fost colectate folosind aplicația dezvoltată, acest lucru poate reprezenta o problemă deoarece volumul de date necesar unei predicții precise nu este suficient de mare. Acest aspect poate fi remediat pe viitor prin colectarea datelor

pe o perioada mai lunga (luni sau ani, luând astfel in considerare modificările aduse de schimbarea de sezon). O alta problema ar putea fi, așa cum am văzut si in capitolul 4, amplasarea senzorilor pe plăcută de test. Căldura radiata de senzorii MQ putând sa afecteze senzorii de temperatura.

7. Bibliografie

- [1] Calitatea aerului in Romania, <http://www.mmediu.ro/categorie/calitatea-aerului/56>
- [2] UN, Revision of world urbanization prospects, <https://www.un.org/development/desa/en/news/population/2018-revision-of-world-urbanization-prospects.html>
- [3] Gradul de urbanizare in Romania, <http://starea-natiunii.ro/index.php/ro/noutati/facts-figures/25-facts-figures/134-romania-se-mentine-pe-ultimul-loc-in-regiune-in-ceea-ce-priveste-gradul-de-urbanizare>
- [4] What is Java, https://java.com/en/download/help/whatis_java.html
- [5] JDK 11 Documentation, <https://docs.oracle.com/en/java/javase/11/>
- [6] What is JavaFX, <https://docs.oracle.com/javafx/2/overview/jfxpub-overview.htm>
- [7] What is Python, <https://www.python.org/doc/essays/blurb/>
- [8] Scikit guide, https://scikit-learn.org/stable/getting_started.html
- [9] Arduino UNO overview, <https://docs.arduino.cc/hardware/uno-rev3>
- [10] Open Electronics, Presenting MQ sensors, <https://www.open-electronics.org/presenting-mq-sensors-low-cost-gas-and-pollution-detectors/>
- [11] DHT11 Datasheet, <https://www.mouser.com/datasheet/2/758/DHT11-Technical-Data-Sheet-Translated-Version-1143054.pdf>
- [12] BMP280 Datasheet, https://www.bosch-sensortec.com/media/boschsensortec/downloads/product_flyer/bst-bmp280-fl000.pdf
- [13] David Mintz (September 2018). Technical Assistance Document for the Reporting of Daily Air Quality – the Air Quality Index (AQI) (PDF). North Carolina: US EPA Office of Air Quality Planning and Standards. EPA-454/B-18-007. Retrieved 15 September 2021
<https://www.airnow.gov/sites/default/files/2020-05/aqi-technical-assistance-document-sept2018.pdf>

8. Lista contribuțiilor personale

Aplicație pentru analiza calității aerului Student: Aldea Andrei Coordonator: Prof. Radu Hobincu		
	Activitate	Durata [zile]
1	Documentare tehnologii necesare in realizarea proiectului	3
2	Realizarea unui prototip al aplicației pentru testarea funcționalităților de baza	5
3	Dezvoltarea codului proiectului	10
4	Realizarea modulului hardware	3
5	Testarea si verificarea datelor colectate de senzori	1
6	Dezvoltarea codului necesare predicției poluanților	2
7	Antrenarea si evaluarea modelului de predicție	4
8	Finalizarea proiectului, modificări finale	2
9	Redactarea lucrării	6
	Total	36

Durata este exprimată în zile echivalente de lucru, adică 1 zi = 8 ore

9. Anexe

Anexa 1 – Codul folosit pentru colectarea datelor cu Arduino.

```
#include <Adafruit_BMP280.h>
#include "DHT.h"

#define DHTPIN 2
#define DHTTYPE DHT11

DHT dht(DHTPIN, DHTTYPE);
Adafruit_BMP280 bmp; // I2C Interface

int coA = A1;
int qA = A0;

void setup() {
  Serial.begin(9600);
  Serial.println(F("[TEST] DHT11"));
  Serial.println(F("[TEST] BMP280"));

  dht.begin();
  boolean bmpStatus = bmp.begin(0x76);
  Serial.println(F("[STATUS] BMP280=" + String(bmpStatus)));

  if (!bmpStatus) {
    Serial.println(F("[ERROR] Could not find a valid BMP280 sensor, check wiring!"));
    while (1);
  }

  /* Default settings from datasheet. */
  bmp.setSampling(Adafruit_BMP280::MODE_NORMAL,
  /* Operating Mode. */
                  Adafruit_BMP280::SAMPLING_X2,
  /* Temp. oversampling */
                  Adafruit_BMP280::SAMPLING_X16,
  /* Pressure oversampling */
                  Adafruit_BMP280::FILTER_X16,
  /* Filtering. */
                  Adafruit_BMP280::STANDBY_MS_500); /* Standby time. */

  pinMode(coA, INPUT);
  pinMode(qA, INPUT);
}

void loop() {
  // Wait a few seconds between measurements.
  delay(2000);

  //read data from BMP
  float temperature_bmp = bmp.readTemperature();
  float pressure_bmp = bmp.readPressure()/100;
  float altitude_bmp = bmp.readAltitude(1017);
  //The pressure(hPa) at sea level

  //read data from DHT
  float temperature_dht = dht.readTemperature();
  float humidity_dht = dht.readHumidity();

  //read data from MQ-135
  float co2comp = analogRead(coA);
  float co2ppm = map(co2comp,0,1023,400,5000);

  //read data from MQ-7
  float q = analogRead(qA);

  // Check if any reads failed and exit early (to try again)
  if (isnan(temperature_dht) || isnan(humidity_dht))
  {
    Serial.println(F("Failed to read from DHT sensor!"));
    return;
  }
}
```

```

    }

    if(isnan(temperature_bmp) ||
    isnan(pressure_bmp) || isnan(altitude_bmp))

    {
        Serial.println(F("Failed to read from BMP
        sensor!"));

        return;
    }

    // Compute heat index in Celsius (isFahreheit
    = false)

    float          heatIndex_dht          =
    dht.computeHeatIndex(temperature_dht,
    humidity_dht, false);

```

```

Serial.println(
    "{"temperature_dht\":" + " +
    String(temperature_dht) + ", " +
    "\"humidity_dht\":" + " + String(humidity_dht)
    + ", " +
    "\"heatIndex_dht\":" + " +
    String(heatIndex_dht) + ", " +
    "\"temperature_bmp\":" + " +
    String(temperature_bmp) + ", " +
    "\"pressure_bmp\":" + " + String(pressure_bmp)
    + ", " +
    "\"altitude_bmp\":" + " + String(altitude_bmp)
    + ", " +
    "\"co2ppm\":" + " + String(co2ppm) + ", " +
    "\"q\":" + " + String(q) + "}"
);

```

Anexa 2 – Codul folosit in analiza rezultatelor

```

%% init

import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
from sklearn.metrics import mean_squared_error

# Importing the dataset

datas = pd.read_csv('data_predict_2.csv',
encoding= 'unicode_escape')

w, h = 25, 18
data = [[0 for x in range(w)] for y in range(h)]

%%

curr_station = 0
max_station = h

curr_pos = 0

for index, row in datas.iterrows():

    data[curr_station][curr_pos] = [row['pm10'],
row['pm10_next']]

```

```

curr_station += 1

if curr_station == max_station:
    curr_station = 0;
    curr_pos += 1

rmse_list = []

print("--- valorile RMSE pentru fiecare statie -
--")

for i in range(h):
    station_data = data[:,i]

    y = []
    y_pred = []

    for j in range(w):
        y.append(station_data[j][0])
        y_pred.append(station_data[j][1])

    y.pop(0)

```

```

y_pred.pop(-1)

rmse = np.sqrt(mean_squared_error(y,
y_pred))

rmse_list.append(rmse)

print("Statia", i, ": RMSE =", rmse)

print("")
print("--- valoarea medie RMSE ---")
print("Mean RMSE:", np.mean(rmse_list))

###
station_data = data[:,7]

y = []
y_pred = []

for j in range(w):
    y.append(station_data[j][0])
    y_pred.append(station_data[j][1])

y.pop(0)
y_pred.pop(-1)

plt.title("Valoarea concentratiei PM10 reale si
Valoarea concentratiei PM10 prezise")
plt.xlabel("Ora")
plt.ylabel("Concentratia medie PM10 [µg/m3]")
plt.grid(color='black', linestyle='-', linewidth=0.1)
plt.plot(y)
plt.plot(y_pred)
plt.xticks(np.arange(0, len(y)+1, 2))
plt.legend(["Valoarea reala", "Valoarea
prezisa"])
plt.show()

```

Anexa 3 - Codul folosit in căutarea coeficienților de regresie

```

### init
import numpy as np
import pandas as pd

from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error

DEG = 4

#date,h,name,wind_speed,temp,hum,co,no,no2,o3,so
2,pm2_5,pm10,nh3,co next,no next,no2 next,o3
next,so2 next,pm2_5 next,pm10 next,nh3 next

# Importing the dataset

datas = pd.read_csv('csv\data_.csv', encoding=
'unicode_escape')

min_simple = 0

### SIMPLE TEST
print("\nCAUTARE COEFICIENTI")

#input data
co_in = datas.iloc[:, [3, 6]] .values
no_in = datas.iloc[:, [3, 7]] .values
no2_in = datas.iloc[:, [3, 8]] .values
o3_in = datas.iloc[:, [3, 9]] .values
so2_in = datas.iloc[:, [3, 10]] .values
pm2_5_in = datas.iloc[:, [3, 11]] .values
pm10_in = datas.iloc[:, [3, 12]] .values
nh3_in = datas.iloc[:, [3, 13]] .values

```

```

#out data
co_out    = datas.iloc[:,14].values
no_out    = datas.iloc[:,15].values
no2_out   = datas.iloc[:,16].values
o3_out    = datas.iloc[:,17].values
so2_out   = datas.iloc[:,18].values
pm2_5_out = datas.iloc[:,19].values
pm10_out  = datas.iloc[:,20].values
nh3_out   = datas.iloc[:,21].values

#regres
poly      = PolynomialFeatures(degree=DEG,
include_bias=True)
poly_features = poly.fit_transform(co_in)

X_train, X_test, y_train, y_test =
train_test_split(poly_features, co_out,
test_size=0.3, random_state=42)

poly_reg_model = LinearRegression()
poly_reg_model.fit(X_train, y_train)
print(poly.get_feature_names())

poly_reg_y_predicted =
poly_reg_model.predict(X_test)

poly_reg_rmse =
np.sqrt(mean_squared_error(y_test,
poly_reg_y_predicted))
print("co", poly_reg_rmse)

coef = ", ".join([str(i) for i in
poly_reg_model.coef_])
print(coef)
print("interc:", poly_reg_model.intercept_)
print("")

poly      = PolynomialFeatures(degree=DEG,
include_bias=True)
poly_features = poly.fit_transform(no_in)

X_train, X_test, y_train, y_test =
train_test_split(poly_features, no_out,
test_size=0.3, random_state=42)

```

```

poly_reg_model = LinearRegression()
poly_reg_model.fit(X_train, y_train)

poly_reg_y_predicted =
poly_reg_model.predict(X_test)

poly_reg_rmse =
np.sqrt(mean_squared_error(y_test,
poly_reg_y_predicted))
print("no", poly_reg_rmse)

coef = ", ".join([str(i) for i in
poly_reg_model.coef_])
print(coef)
print("interc:", poly_reg_model.intercept_)
print("")

poly      = PolynomialFeatures(degree=DEG,
include_bias=True)
poly_features = poly.fit_transform(no2_in)

X_train, X_test, y_train, y_test =
train_test_split(poly_features, no2_out,
test_size=0.3, random_state=42)

poly_reg_model = LinearRegression()
poly_reg_model.fit(X_train, y_train)

poly_reg_y_predicted =
poly_reg_model.predict(X_test)

poly_reg_rmse =
np.sqrt(mean_squared_error(y_test,
poly_reg_y_predicted))
print("no2", poly_reg_rmse)

coef = ", ".join([str(i) for i in
poly_reg_model.coef_])
print(coef)
print("interc:", poly_reg_model.intercept_)
print("")

poly      = PolynomialFeatures(degree=DEG,
include_bias=True)

```

```

poly_features = poly.fit_transform(o3_in)

X_train, X_test, y_train, y_test =
train_test_split(poly_features, o3_out,
test_size=0.3, random_state=42)

poly_reg_model = LinearRegression()
poly_reg_model.fit(X_train, y_train)

poly_reg_y_predicted =
poly_reg_model.predict(X_test)

poly_reg_rmse =
np.sqrt(mean_squared_error(y_test,
poly_reg_y_predicted))

print("o3", poly_reg_rmse)

coef = ", ".join([str(i) for i in
poly_reg_model.coef_])

print(coef)

print("interc:", poly_reg_model.intercept_)

print("")

poly = PolynomialFeatures(degree=DEG,
include_bias=True)

poly_features = poly.fit_transform(so2_in)

X_train, X_test, y_train, y_test =
train_test_split(poly_features, so2_out,
test_size=0.3, random_state=42)

poly_reg_model = LinearRegression()
poly_reg_model.fit(X_train, y_train)

poly_reg_y_predicted =
poly_reg_model.predict(X_test)

poly_reg_rmse =
np.sqrt(mean_squared_error(y_test,
poly_reg_y_predicted))

print("so2", poly_reg_rmse)

coef = ", ".join([str(i) for i in
poly_reg_model.coef_])

print(coef)

print("interc:", poly_reg_model.intercept_)

print("")

```

```

poly = PolynomialFeatures(degree=DEG,
include_bias=True)

poly_features = poly.fit_transform(pm2_5_in)

X_train, X_test, y_train, y_test =
train_test_split(poly_features, pm2_5_out,
test_size=0.3, random_state=42)

poly_reg_model = LinearRegression()
poly_reg_model.fit(X_train, y_train)

poly_reg_y_predicted =
poly_reg_model.predict(X_test)

poly_reg_rmse =
np.sqrt(mean_squared_error(y_test,
poly_reg_y_predicted))

print("pm2_5", poly_reg_rmse)

coef = ", ".join([str(i) for i in
poly_reg_model.coef_])

print(coef)

print("interc:", poly_reg_model.intercept_)

print("")

poly = PolynomialFeatures(degree=DEG,
include_bias=True)

poly_features = poly.fit_transform(pm10_in)

X_train, X_test, y_train, y_test =
train_test_split(poly_features, pm10_out,
test_size=0.3, random_state=42)

poly_reg_model = LinearRegression()
poly_reg_model.fit(X_train, y_train)

poly_reg_y_predicted =
poly_reg_model.predict(X_test)

poly_reg_rmse =
np.sqrt(mean_squared_error(y_test,
poly_reg_y_predicted))

print("pm10", poly_reg_rmse)

```

```

coef = ",".join([str(i) for i in
poly_reg_model.coef_])

print(coef)

print("interc:", poly_reg_model.intercept_)

print("")

```

```

poly = PolynomialFeatures(degree=DEG,
include_bias=True)

poly_features = poly.fit_transform(nh3_in)

X_train, X_test, y_train, y_test =
train_test_split(poly_features, nh3_out,
test_size=0.3, random_state=42)

```

```

poly_reg_model = LinearRegression()

poly_reg_model.fit(X_train, y_train)

```

```

poly_reg_y_predicted =
poly_reg_model.predict(X_test)

```

```

poly_reg_rmse =
np.sqrt(mean_squared_error(y_test,
poly_reg_y_predicted))

```

```

print("nh3", poly_reg_rmse)

```

```

coef = ",".join([str(i) for i in
poly_reg_model.coef_])

```

```

print(coef)

```

```

print("interc:", poly_reg_model.intercept_)

```

```

print("")

```